VERİ ANALİZİ OKULU

2025-2026

Makine Öğrenmesi - 2

Dr. Öğr. Üyesi M. Fuat KINA

Marmara Üniversitesi

Nüfus ve Sosyal Araştırmalar Enstitüsü

Dersin Çerçevesi

1. İleri Makine Öğrenmesi Modelleri

- Naive Bayes Sınıflandırma
- Support Vector Machines
- Decision Trees (Karar Ağaçları) and Random Forests
- Principal Component Analysis (Temel Bileşen Analizi)

2. Derin Öğrenme

- Neural networks (Sinir Ağları)

1. İleri Makine Öğrenmesi

Naive Bayes Sınıflandırma

- Gözetimli öğrenme: Sınıflandırıcı (Classifier)
- Bayes teoremine dayanır (naif varsayım ile).
- *Gaussian, Multinomial, Complement, Bernoulli...*

$$P(\text{parameters}|\text{data}) = \frac{P(\text{data}|\text{parameters}) * P(\text{parameters})}{P(\text{data})}$$

P(parameters|data) -> posterior distribution what we know about parameters after we see the data

P(parameters) -> prior distribution what we know about parameters

P(data|parameters) -> likelihood the data according to statistical model

Support Vector Machines

- Gözetimli Öğrenme: Sınıflandırıcı (Classifier) SVM (Support Vector Machine), eğitim örneklerini uzaydaki noktalara eşler ve iki kategori arasındaki boşluğun (margin) genişliğini maksimize etmeye çalışır.
- N-boyutlu bir uzay düşün.
- İki gruptaki en yakın noktalara olan mesafeyi mümkün olduğunca büyük tutacak şekilde bir sınır (ayırıcı hiper-düzlem) bulur.
- Kernel seçebilirsin: linear, polynomial, RBF...

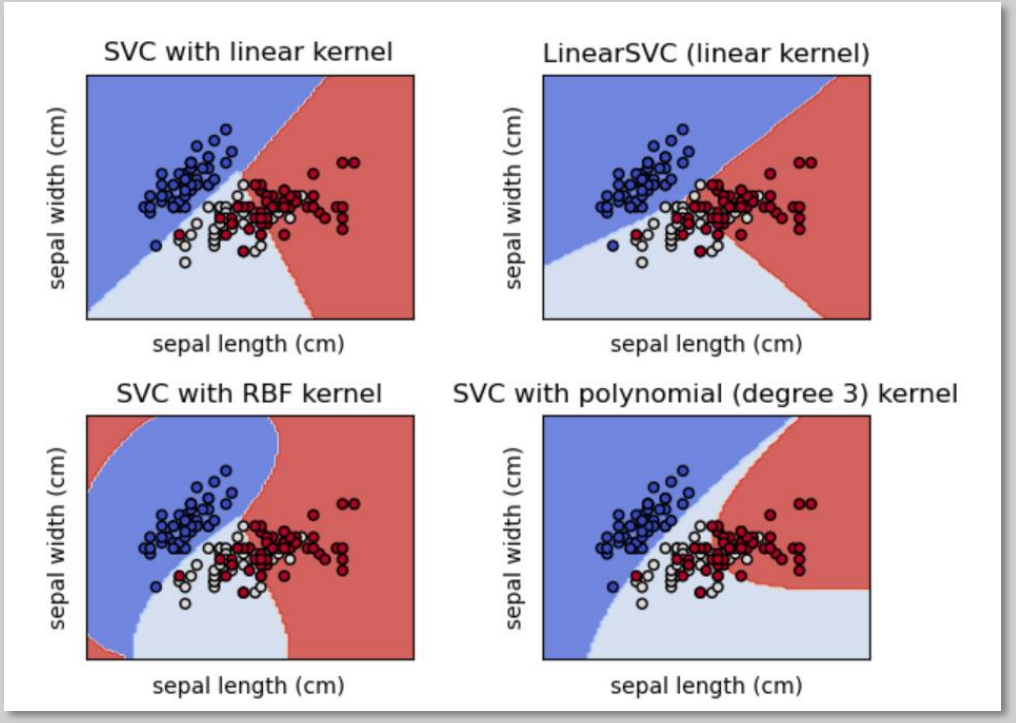

Decision Trees (Karar Ağaçları) and Random Forests

- Gözetimli öğrenme. Amaç, veri özelliklerinden çıkarılan basit karar kurallarını öğrenerek bir hedef değişkenin değerini tahmin eden bir model oluşturmaktır. Bir ağaç, parça parça sabit (piecewise constant) bir yaklaşım/approximation olarak düşünülebilir.
- Hem kategorik hem de sürekli hedef değişkenlerle çalışır.
  - Random forest için: ağaç sayısını (number of trees) belirleyelim.
  - Bölme (split) kriterleri: Gini, entropy, chi-square vb.
  - Overfitting'i önlemek için ağacın maksimum derinliğini (dikey derinlik) belirleyelim. Derinlik arttıkça model, belirli bir örnekleme özgü ilişkileri daha iyi öğrenebilir; bu yüzden CV (cross-validation) ile ayarlanabilir.

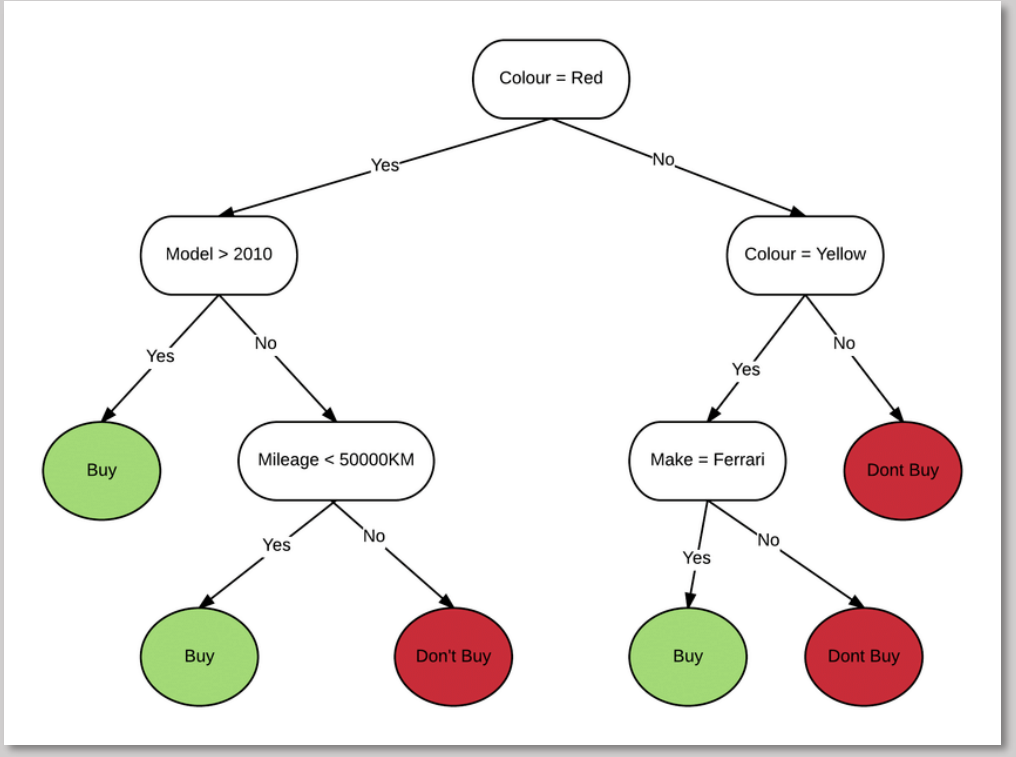

Quiz

Spam dedektifi: Bir e-postanın spam olma olasılığını, içindeki kelimelere bakarak hızlıca tahmin etmek istiyorsun. Aşağıdakilerden hangisi Naive Bayes'in en temel fikrini en iyi anlatır?

A) Veriyi çizip en iyi çizgiyi bulurum.
B) Önce 'öncül (prior)' bilgiyi alırım, yeni veri gelince güncellerim.
C) Ağaç gibi dallanıp budaklanırım, sonra oylama yaparım.
D) Boyutu düşürürüm, varyansı azaltırım.

Principal Component Analysis (Temel Bileşen Analizi)

- Gözetimsiz öğrenme
  Verinin temel bileşenlerini (principal components) hesaplama ve bu bileşenleri kullanarak veride baz (basis) dönüşümü yapma sürecidir.
- Varyansı maksimize eder.
- Ortogonal boyutlar çıkarır.
- Verinin boyutlarını dekorele eder: PCA ile elde edilen özellikler birbiriyle korelasyonlu değildir.

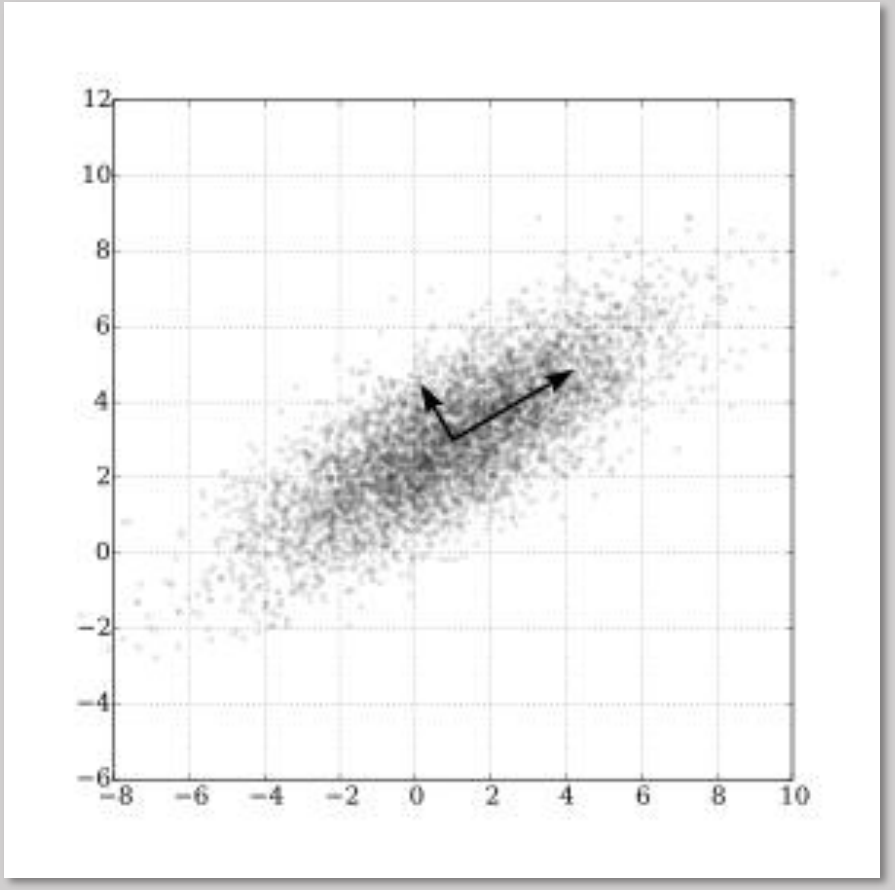

Quiz

Elinde 50 özellik (feature) var ve bu kadar özelliği işleyecek veri için yeterli hesaplama gücün yok. Özellik sayısını azaltıp verinin ana yapısını korumak istiyorsun. Aşağıdakilerden hangisi PCA için doğrudur?

A) Gözetimli öğrenmedir; etiket (label) şarttır.
B) Varyansı maksimize eden yeni, ortogonal boyutlar üretir.
C) Sadece metin verisinde çalışır.
D) Overfitting'i artırmak için maksimum derinliği yükseltir.

2. Derin Öğrenmeye Giriş

Neural networks (Sinir Ağları)

- **Temel amaç:** İnsan beynine benzer şekilde örüntüleri/nesneleri tanımak.
- **İnsan sinir sisteminden** esinlenmiştir.
- Gözetimli öğrenme kapsamında kullanılabilir.

  - Python'da scikit-learn ile kolayca çalıştırılabilir.
  - Özellikle farklı türde özellikleri (feature) birlikte analiz etmek istendiğinde çok verimlidir.

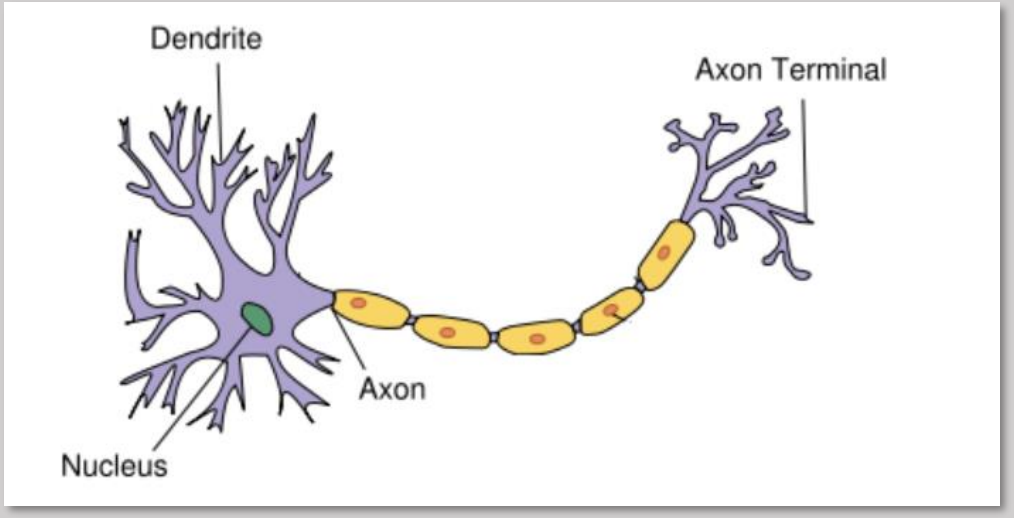

Neural networks (Sinir Ağları)

- En basit sinir ağı, yalnızca **tek bir nörondan** oluşur ve yukarıdaki şekilde gösterildiği gibi **perceptron** olarak adlandırılır.

- Soldaki ilk düğüm (node) grubu, verideki özellik (feature) sayısı ile aynıdır.

- Yapay Sinir Ağı (Çok Katmanlı Algılayıcı / Multilayer Perceptron, MLP)

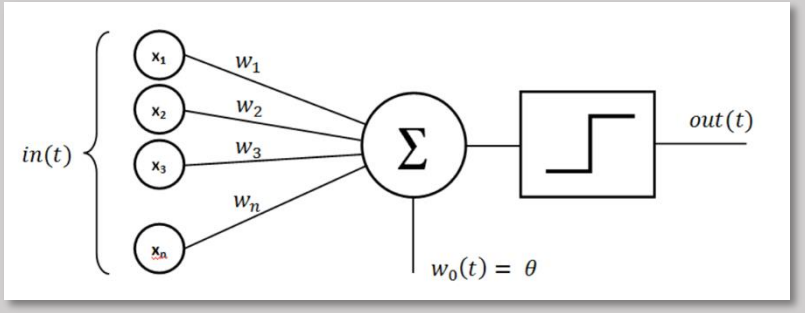

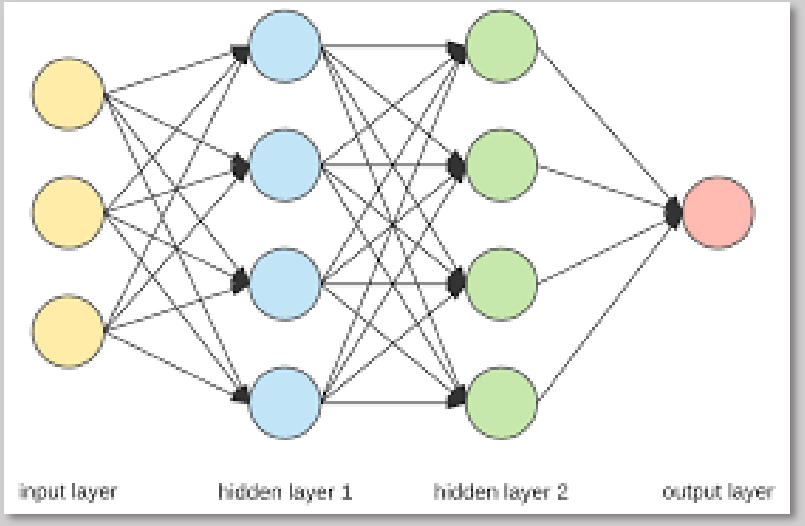

Yapay Sinir Ağları

- **İleri yayılım (Forward Propagation):** Girdiyi ağırlıklandırıp aktivasyon fonksiyonunu çalıştırarak çıktı katmanına ulaşma süreci
  - Girdi katmanına gelen değerler ağırlıklarla çarpılır, üzerine bir bias (sabit terim) eklenir.
  - İlk gizli katmanda nöronlar, girdi katmanından gelen değer üzerinde çalışan bir aktivasyon fonksiyonuna sahiptir.
  - İlk gizli katmandan çıkan çıktılar, ikinci gizli katmanın ağırlıklarıyla çarpılır (katman katman ilerler).
- **Geri yayılım (Back Propagation)**
  - Hata, tahmin edilen çıktı ile istenen (gerçek) çıktı arasındaki fark ölçülerek hesaplanır.
  - Amaç: **hatayı minimize etmek!!!**
  - Bunun için de bir optimizasyon fonksiyonu çalışır.

Yapay Sinir Ağları (Uygulama - Sklearn and Keras)

- **Mimarîyi (architecture) belirle**
  - Kaç katman istiyorsun? Her katmanda kaç düğüm (node) olacak?
  - Her katmanda hangi aktivasyon fonksiyonunu kullanmak istiyorsun?
    - Identity (kimlik) fonksiyonu, ReLU, softmax vb.
- **Compile (derleme)**
  - Bu adım kayıp (loss) fonksiyonunu ve optimizasyonun nasıl çalışacağına dair bazı detayları belirler.
  - Kayıp fonksiyonu: Mean Squared Error (MSE), categorical_crossentropy
  - Optimizasyon algoritması (optimizer): Adam

- **Modeli eğit (fit the model)**
- **Sonucu tahmin et (predict the outcome)**

Quiz

Bir sinir ağıyla nadir görülen bir şeyi (ör. “arızalı ürün”, “hastalık”, “sahte hesap”) yakalamaya çalışıyorsun. Eğitim sonunda accuracy (doğruluk) yüksek görünüyor ama model pratikte çoğu zaman “yok” deyip asıl önemli olan örnekleri kaçırıyor.

Bu durumda en doğru yorum/çözüm hangisidir?

A) Model zaten çok iyi; accuracy yüksekse sorun yok.
B) Accuracy yanıltıcı olabilir. F1 / precision-recall gibi ölçülere bakıp gerekirse az görülen sınıfa daha fazla ağırlık verilebilir.
C) ReLU yerine sigmoid koyarsam bir çok şey düzelir.
D) Katman sayısını azaltırsam performans artar, sorun çözülür.